

Aprendizaje automático  
Proyecto Capstone  
Prof. Carlos B. Ogando M.**PROYECTO CAPSTONE: PREDICCIÓN DEPORTIVA****HONESTIDAD ACADÉMICA**

Como de costumbre, se aplica el código de honor estándar y la política de probidad académica. Las presentaciones isomórficas a (1) las que existen en cualquier lugar en línea, (2) las enviadas por sus compañeros de clase, o (3) las enviadas por los estudiantes en semestres anteriores serán consideradas plagio.

**INSTRUCCIONES**

En este proyecto integrador tipo **Capstone** desarrollarán un **modelo predicción deportiva** empleando los conocimientos aprendidos durante la materia.

**I. Resumen****II. Introducción****III. Detalles de implementación****IV. Requerimientos de la entrega****I. Resumen**

El objetivo de este proyecto es desarrollar un sistema de inteligencia artificial capaz de **predecir el resultado de eventos deportivos** utilizando información histórica de jugadores o equipos.

Cada grupo podrá seleccionar libremente el deporte de su interés, siempre que disponga de una cantidad suficiente de datos históricos.

**II. Introducción**

La predicción de eventos deportivos constituye uno de los problemas más estudiados dentro del área de la ciencia de datos y el aprendizaje automático. Cada encuentro deportivo representa un sistema complejo en el que intervienen múltiples factores, tales como el rendimiento histórico de los participantes, la experiencia, las condiciones del evento, las tendencias recientes, las características del escenario y diversos aspectos estratégicos propios de cada disciplina.

En la actualidad, organizaciones deportivas, medios de comunicación, empresas de análisis estadístico, casas de apuestas y equipos profesionales utilizan modelos predictivos para estimar probabilidades de victoria, evaluar el desempeño de jugadores y equipos, apoyar la toma de decisiones y generar análisis avanzados de competiciones deportivas.

El desarrollo de sistemas de predicción deportiva posee una gran relevancia académica debido a que integra múltiples etapas fundamentales de un proyecto de ciencia de datos. Entre ellas se encuentran la recolección y preparación de datos históricos, la ingeniería de características, el análisis exploratorio, la construcción de modelos de aprendizaje automático, la evaluación de resultados y la implementación de sistemas de inferencia.

A diferencia de otros problemas de clasificación tradicionales, la predicción deportiva presenta un desafío adicional: las variables más importantes no suelen encontrarse directamente en los datos originales, sino que deben construirse a partir del comportamiento histórico de los jugadores o equipos. Por esta razón, el éxito de estos sistemas depende en gran medida de la capacidad para diseñar variables representativas que capturen información relevante del desempeño pasado.

Este proyecto permitirá a los estudiantes experimentar con un problema real ampliamente estudiado en la industria, aplicando técnicas de inteligencia artificial a diferentes disciplinas deportivas, tales como fútbol, baloncesto, béisbol, tenis, voleibol, boxeo, automovilismo o cualquier otro deporte que disponga de información histórica suficiente.

El objetivo final consiste en desarrollar un sistema capaz de estimar la probabilidad de ocurrencia de un resultado deportivo utilizando exclusivamente información disponible antes del evento, reproduciendo así las condiciones reales bajo las cuales operan numerosos sistemas de análisis y predicción utilizados en la actualidad.

### III.- Detalles de implementación

#### Descripción del problema

Dado un evento deportivo futuro:

Equipo A vs Equipo B

o

Jugador A vs Jugador B

el sistema deberá estimar la probabilidad de victoria de cada participante.

#### Aspectos de implementación

En este proyecto se evaluará cómo pueden integrar los conocimientos empleados en la materia para resolver la problemática de predicción deportiva en un caso de uso basado en la realidad.

- Inteligencia de enjambre → "¿Cómo pueden muchos agentes simples resolver colectivamente un problema de optimización?"
- Algoritmos genéticos → "¿Cómo puede la evolución buscar buenas soluciones?"

- Aprendizaje federado → "¿Cómo pueden múltiples partes aprender juntas sin compartir datos?"

## IV.- Requerimientos de la entrega

Su trabajo está en desarrollar una solución integrando los conocimientos de la materia que permita resolver el problema de predicción deportiva.

Para completar satisfactoriamente este proyecto es necesario cumplir los siguientes requerimientos:

### PARTE 1: Requerimientos de recopilación de datos

Cada grupo deberá:

#### 1.1. Seleccionar un deporte.

Ejemplos:

- Fútbol
- Baloncesto
- Béisbol
- Tenis
- Voleibol
- Boxeo
- Fórmula 1
- NASCAR
- MMA
- Esports

#### 1.2. Obtener una base de datos histórica.

- El dataset debe tener al menos 50,000 filas.

### PARTE 2: Requerimientos de procesamiento de datos

#### 2.1. Preprocessing

- Debe tener al menos 10 features que permitan estimar la predicción.
- La etiqueta de salida debe ser la categoría de si ganó o no un encuentro.
- Deben realizar un análisis de la calidad de datos (cantidad de celdas nulas, cantidad de celdas mal formateadas, entre otros)
- Obtener estadísticas básicas de las columnas (promedio, mediana, mínimo, máximo, desviación estándar)
- Ver las distribuciones de los datos de cada columna.
- Analizar estas distribuciones en conjunto con otras variables
- Identificar correlaciones entre las variables.
- Otros hallazgos.

#### 2.2. Construir variables históricas.

No se permitirá utilizar información futura.

Todas las características deberán calcularse únicamente con información disponible antes del evento.

### Ejemplos de variables

- Fútbol
  - Victorias en los últimos 5 partidos.
  - Goles anotados promedio.
  - Goles recibidos.
  - Posición en la tabla.
  - Historial entre ambos equipos.
  - Rendimiento de local y visitante.
- Baloncesto
  - Promedio de puntos.
  - Rebotes.
  - Asistencias.
  - Racha de victorias.
  - Eficiencia ofensiva.
- Béisbol
  - ERA del pitcher.
  - Promedio de bateo.
  - Victorias recientes.
  - Rendimiento como local.
- Tenis
  - Ranking ATP/WT.
  - Historial entre jugadores.
  - Rendimiento en superficie.
  - Experiencia.
  - Porcentaje de victorias.

### Sobre la ingeniería de características

Las variables deberán representar diferencias entre los participantes.

Ejemplos:

- ranking\_diff
- win\_rate\_diff
- goals\_diff
- experience\_diff
- h2h\_diff

### PARTE 3: Requerimientos de implementación de modelo.

- El único requerimiento duro es que debe calibrar las probabilidades del modelo resultante. Luego de eso, la implementación es completamente abierta.
- La idea es que demuestren cómo emplear los conocimientos aprendidos en la materia para complementar y definir la realización de su solución propuesta.

**IMPORTANTE:** Si un proyecto no usa ningún conocimiento clave aprendido en la materia valdrá cero. Los temas que deben tomar en cuenta para incluir son:

- Inteligencia de enjambre
- Algoritmos genéticos
- Aprendizaje federado

#### **PARTE 4: Evaluación e inferencia**

El proyecto deberá incluir una interfaz sencilla que permita ingresar un encuentro futuro.

Ejemplo:

Equipo A: Lakers

Equipo B: Celtics

Temporada: 2025

El sistema deberá mostrar:

Probabilidad Lakers: 63%

Probabilidad Celtics: 37%

Predicción: Lakers

Puede implementarse mediante:

- Consola
- Notebook interactivo.
- Widgets de Jupyter.
- Streamlit.
- Gradio.
- Aplicación web sencilla.

Para la presentación de sus resultados deben incluir benchmarks y detalle de las pruebas hechas de acuerdo con la implementación que decidan hacer.

#### **PARTE 5: Otras documentaciones**

Debe entregar un **documento de infraestructura** del proyecto que contenga el detalle técnico de la implementación y resultados del proyecto.

### **Restricciones importantes**

- No se permite utilizar variables que contengan información posterior al evento.
- No se permite entrenar utilizando información futura.
- No se permite usar únicamente estadísticas del partido actual.

Debe exponer el proyecto en clase, de lo contrario, no valdrá puntos.